



# BUILDING AN ETL PIPELINE: DEKORUMA E-COMMERCE DATA

COMPREHENSIVE DATA ANALYTICS PROGRAM

> Start Slide



# REFERENCE

WEBSITE

Website Dekoruma

COLAB NOTEBOOK

Project Link (Available on Github)



#### **Objective of The Project**

- Build an end-to-end ETL pipeline with a manual staging step.
- Practice web scraping, data cleaning, and data preparation in Python.
- Store the processed data in a CSV file before database ingestion.
- Understand the workflow of combining automated processing with manual data import into PostgreSQL.
- Strengthen familiarity with Python–PostgreSQL integration via CSV workflows.










#### **Libraries Needed**





## Website Scraping

Aspect	Details		
Scraping Method	Selenium + BeautifulSoup		
Pages Collected	5 pages		
Scrolling	Automated scrolling to load all products		
Captured Fields	<ul> <li>Nama Produk</li> <li>Harga Sebelum Diskon</li> <li>Diskon</li> <li>Harga Setelah Diskon</li> <li>Jumlah Terjual atau Ulasan</li> <li>Gratis Ongkir</li> </ul>		
Total Records	120 rows		

	Nama Produk	Harga Sebelum Diskon	Diskon	Harga Setelah Diskon	Jumlah Terjual atau Ulasan	Gratis Ongkir
0	Heim Studio KOZU Coffee Table 2in1	Rp1,485,000	42%	Rp859,000	(4055 Terjual)	se- Jabodetabek
1	Heim Studio KOZU Meja Kerja	Rp1,980,000	47%	Rp1,049,000	(3612 Terjual)	se- Jabodetabek
2	Heim Studio NANA Meja TV 2in1	Rp2,178,000	52%	Rp1,029,000	(2661 Terjual)	se- Jabodetabek
3	Heim Studio ISY Meja TV	Rp1,434,000	39%	Rp869,000	(3153 Terjual)	se- Jabodetabek
4	Heim Studio YVER Meja Makan Multifungsi	Rp3,636,000	48%	Rp1,859,000	(3135 Terjual)	se- Jabodetabek
115	Tenzo Living ALANO Meja Tamu	Rp8,670,000	25%	Rp6,499,000	None	se- Jabodetabek
116	Tenzo Living VERLIN Meja Tamu	Rp10,000,000	25%	Rp7,499,000	None	se- Jabodetabek
117	Heim Studio SOKA Meja Makan	Rp4,053,000	42%	Rp2,349,000	(5 Ulasan)	se- Jabodetabek
118	Cubic Cubic Meja Komputer Rumah - Meja Kerja L	Rp430,000	50%	Rp215,000	(34 Terjual)	se-Jawa
119	Cubic Cubic Rak TV minimalis - Meja TV Minimal	Rp1,397,000	57%	Rp592,000	(1 Ulasan)	se-Jawa



### **Data Exploration**

No.	Column Name	Description	Non-Null Count/ Total	Data Type	Notes
1	Nama Produk	Product names scraped from Dekoruma	120/120	object	No missing values; data type correct (text)
2	Harga Sebelum Diskon	Original prices before discounts	120/120	object	Should be integer; must remove "Rp" and commas
3	Diskon	Discount percentages	114/120	object	Should be float; contains missing values (products without discounts); must remove "%" and scale to decimals
4	Harga Setelah Diskon	Prices after discounts	120/120	object	Should be integer; must remove "Rp" and commas
5	Jumlah Terjual atau Ulasan	Number sold or reviews	101/120	object	Missing values, contains brackets "()"
6	Gratis Ongkir	Free shipping information	120/120	object	No missing values; data type correct (text)



## **Data Cleaning**

Column	Cleaning Actions	Result
Harga Sebelum Diskon	<ul><li>Remove "Rp"and commas</li><li>Convert to integer</li></ul>	Int64, clean format
Diskon	<ul> <li>Remove "%"</li> <li>Convert to float</li> <li>Divide by 100 (decimal)</li> <li>Replace NaN with 0</li> </ul>	float64, no missing values
Harga Setelah Diskon	<ul><li>Remove "Rp" and commas</li><li>Convert to integer</li></ul>	Int64, clean format
Jumlah Terjual/Ulasan	<ul> <li>Remove brackets "()"</li> <li>Replace missing values with "Belum Terjual atau Diulas"</li> </ul>	object, no missing values
Nama Produk & Gratis Ongkir	No changes needed	object, unchanged



#### **Data Exploration (After Cleaning)**

Column	Non-Null Count / Total	Data Type
Nama Produk	120 / 120	object
Harga Sebelum Diskon	120 / 120	Int64
Diskon	120 / 120	float64
Harga Setelah Diskon	120 / 120	Int64
Jumlah Terjual/Ulasan	120 / 120	object
Gratis Ongkir	120 / 120	object

All data cleaned and ready for further analysis.



Save Data to CSV

cleaned\_retail\_data.csv

(without index)



# Create PostgreSQL database and table for staging



-- 1. Membuat Database

Use COPY command to load CSV



If required, normalize fields into separate tables

#### **SQL Preparation**

```
-- Query ini digunakan untuk membuat database
CREATE DATABASE milestone1; -- (Note: Ini seharusnya berada pada halaman query yang berbeda, tetapi saya copy di sini agar menjadi 1 file sql)
-- 2. Membuat Table Staging
-- Query ini digunakan untuk membuat table "staging"
CREATE TABLE staging (
               id SERIAL,
               nama_produk VARCHAR (250),
               harga_sebelum_diskon INT,
               diskon FLOAT,
               harga_setelah_diskon INT,
               jumlah_terjual_ulasan VARCHAR (250),
                gratis ongkir VARCHAR (250)
               );
-- Query ini digunakan untuk mengambil semua data dari tabel "staging", tetapi dalam hal ini digunakan untuk memastikan apakah kolom pada table "staging" sudah sesuai
SELECT * FROM staging;
-- Query ini digunakan untuk memasukkan data pada tabel "staging", di mana data yang digunakan berasal dari file csv
COPY staging (nama_produk, harga_sebelum_diskon, diskon, harga_setelah_diskon, jumlah_terjual_ulasan, gratis_ongkir)
FROM 'C:\Users\cleaned_retail_data.csv' DELIMITER ',' CSV HEADER;
```



# THANKYOU

COMPREHENSIVE DATA ANALYTICS PROGRAM

> End Slide